


SVM的options求解:

两个目标: 样本分对; 最大化Margin (最小化 w 乘以 w 的转置)

样本是两类: $+1, -1$ (标签), $+1$ 的样本必须 $w \cdot x + b \geq 1$, 才是将样本分对。

❖ Correctly classify all data points:

$$\begin{aligned} w \cdot x_i + b &\geq 1 & \text{if } y_i = +1 \\ w \cdot x_i + b &\leq -1 & \text{if } y_i = -1 \\ y_i(w \cdot x_i + b) - 1 &\geq 0 \end{aligned}$$


❖ Maximize the margin:

$$\max M = \frac{2}{\|w\|} \Rightarrow \min \frac{1}{2} w^T w$$



❖ Quadratic Optimization Problem

- Minimize $\Phi(w) = \frac{1}{2} w^T w$
- Subject to $y_i(w \cdot x_i + b) \geq 1$

知乎 @Sandra

最核心的优化函数

拉格朗日乘数法: (拉格朗日系数: α)


$$\begin{aligned} L_P &\equiv \frac{1}{2} \|w\|^2 - \sum_{i=1}^l \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^l \alpha_i \\ \frac{\partial L_P}{\partial w} = 0 &\Rightarrow w = \sum_{i=1}^l \alpha_i y_i x_i \\ \frac{\partial L_P}{\partial b} = 0 &\Rightarrow \sum_{i=1}^l \alpha_i y_i = 0 \\ L_D &\equiv \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i \cdot x_j \\ &\equiv \sum_i \alpha_i - \frac{1}{2} \alpha^T H \alpha \text{ where } H_{ij} = y_i y_j x_i \cdot x_j \\ \text{subject to: } &\sum_i \alpha_i y_i = 0 \text{ \& } \alpha_i \geq 0 \end{aligned}$$


Dual Problem

Quadratic problem again!

知乎 @Sandra

一个不等式, 引入一个拉格朗日函数, α

分别对 w 、 b 求导，结果很重要。将结果带回，得到新的目标函数（与上面的函数是对偶问题）。原问题和对偶问题一般情况下是不等价的，但在SVM情况下满足一些条件，所以是等价的。所以转为求

L_D

的问题，其是由 α 组成的（有条件约束），简化了问题。

解方程，得到很多 α 的值。很多 α 都是=0的，只有少数是不等于0的，这些不等于0的是Support Vectors。因为 $\alpha=0$ 的不对 w 作任何contribution。

Support Vectors : Samples with positive α

$$y_s(x_s \cdot w + b) = 1$$

$$y_s \left(\sum_{m \in S} \alpha_m y_m x_m \cdot x_s + b \right) = 1$$

$$y_s^2 \left(\sum_{m \in S} \alpha_m y_m x_m \cdot x_s + b \right) = y_s$$

$$b = y_s - \sum_{m \in S} \alpha_m y_m x_m \cdot x_s$$

$$b = \frac{1}{N_s} \sum_{s \in S} \left(y_s - \sum_{m \in S} \alpha_m y_m x_m \cdot x_s \right)$$

$$g(x) = \sum_{i=1}^l \alpha_i y_i x_i \cdot x + b$$



inner product



随便挑选一个support vector就可以将 b 求出来。用多个support vectors也可以，求解完累加，再除上个数就可以。

注意

$x_i \cdot x$

是两个向量做内积，这也是SVM的精华所在，很关键。将里面主要的运算都做成向量的内积运算。

随便取了一个support vectors


x_s

，将 w 替换，将方程展开，两边同时乘上

y_s

（为+1或者-1），进行化简。

举例：



$$\sum_{i=1}^2 \alpha_i y_i = 0 \Rightarrow \alpha_1 - \alpha_2 = 0 \Rightarrow \alpha_1 = \alpha_2$$

$$H = \begin{bmatrix} H_{11} & H_{12} \\ H_{21} & H_{22} \end{bmatrix} = \begin{bmatrix} y_1 y_1 x_1 \cdot x_1 & y_1 y_2 x_1 \cdot x_2 \\ y_2 y_1 x_2 \cdot x_1 & y_2 y_2 x_2 \cdot x_2 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix}$$

$$L_D \equiv \sum_{i=1}^2 \alpha_i - \frac{1}{2} [\alpha_1, \alpha_2] H \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix} = 2\alpha_1 - \alpha_1^2$$

$$w = \sum_{i=1}^2 \alpha_i y_i x_i = 1 \times 1 \times [1, 1] + 1 \times (-1) \times [0, 0] = [1, 1]$$

$$\alpha_1 = 1; \alpha_2 = 1$$


$$b = -wx_1 + 1 = -2 + 1 = -1$$

$$g(x) = wx + b = x_1 + x_2 - 1$$

$$M = \frac{2}{\|w\|} = \frac{2}{\sqrt{2}} = \sqrt{2}$$

Soft Margin (处理噪点问题，并不是处理实际上的线性不可分)

原本的情况是假设上平面就为+1，下平面就为-1。但很多情况无法做到完美分割，给你加一个允错范围。当加上它之后你可以都大于0或者小于0，就近似看为全部分对。但由于引入了允错范围，所以还要加上一个惩罚量。



$$y_i (wx_i + b) - 1 + \xi_i \geq 0$$

$$\Phi(w) = \frac{1}{2} w' w + C \sum_i \xi_i$$

$$\xi_i \geq 0$$

$$L_P \equiv \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi_i - \sum_{i=1}^l \alpha_i [y_i (w \cdot x_i + b) - 1 + \xi_i] - \sum_{i=1}^l \mu_i \xi_i$$

两组不等式引入两个拉格朗日函数， α 和 μ

仍按原来的方式求解：

引入了一个soft margin，但最终结果并没有很复杂。

$$\frac{\partial L_p}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^l \alpha_i y_i x_i$$

$$\frac{\partial L_p}{\partial b} = 0 \Rightarrow \sum_{i=1}^l \alpha_i y_i = 0$$

} Same as before

$$\frac{\partial L_p}{\partial \xi_i} = 0 \Rightarrow C = \alpha_i + \mu_i$$

$$L_p \equiv \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi_i - \sum_{i=1}^l \alpha_i [y_i (w \cdot x_i + b) - 1 + \xi_i] - \sum_{i=1}^l \mu_i \xi_i$$

$$L_D \equiv \sum_i \alpha_i - \frac{1}{2} \alpha^T H \alpha \quad s.t. \quad 0 \leq \alpha_i \leq C \quad and \quad \sum_i \alpha_i y_i = 0$$

发现与原来的类似，只有 C 不同